

計量経済学と機械学習の関係 -AI はさだめ, さだめは反事実的-


Relation between Econometrics and Machine Learning: AI is the Plan, the Plan is Counterfactual

@ill-identified

2019/6/29

自己紹介と宣伝

- Twitter: @ill_identified



- ブログ: <http://ill-identified.hatenablog.com/>
- LinkedIn: <https://www.linkedin.com/in/satoshi-katagiri/>
- Twitter: https://twitter.com/ill_Identified
- github: <https://github.com/Gedevan-Aleksizde>
- 現在の勤務先: Web 広告の会社
 - データ分析インターンがあるので適当に探して応募

前回までのあらすじ

- いかがでしたか系登壇をやらかした

いかがでしたか？

- いかがでしたか？ お買得物件を正確に発見する方法を調べてみましたが残念ながらよく分かりませんでした！
- ill_identified 先生の今後の挽回に期待ですね！

前回までのあらすじ

- 機械**学習**を論じたがる人間に**学習**能力はあるのか？

📌 固定されたツイート



ill-identified @ill_Identified · 7月2日

なお, 私は次回 (第80回) の Tokyo.R の応用セッションでも発表する予定ですが, 前回はテーマとしてまとめた結果を出すのに時間がかかるので続編ではなく別のテーマでやる予定です. せっくなので投票を参考にします.

次回の #TokyoR で聞きたいのはどれ:

13% コテコテの統計モデリング

26% 時系列モデリング

46% 計量経済学と機械学習

15% 上記どれでもない一発ネタ

70票 • 最終結果

- 計量経済学側から知りたいなら以下だけで良し (ただし英語)
- Varian (2014)
 - 日本語解説: 『Causal Inference in Economics and Marketing を (今更) 読んだ感想と備忘録』
- Mullainathan and Spiess (2017)
- Athey (2017)
- Imbens (2018)
- Athey (2018)


先行研究?

- 私のブログ
- 過去の考えをアップデートする

2015-10-17

[異種試合] ディープラーニングVSディープパラメータ

論文 計量経済学 経済学 統計学 機械学習




概要今やかなり使い古された感じのあるテーマだが、統計学と機械学習の違いについて、分析の対象が社会現象である場合に限定して自分なりの考えをまとめてみた。例えば、以下のtjo.hatenablog.comでも説明が試みられていて、ここにあるように「統計学は説明...

★+ ★★★

2015-10-17

[異種試合] ディープラーニングVSディープパラメータ

論文 計量経済学 経済学 統計学 機械学習



概要今やかなり使い古された感じのあるテーマだが、統計学と機械学習の違いについて、分析の対象が社会現象である場合に限定して自分なりの考えをまとめてみた。例えば、以下のtjo.hatenablog.comでも説明が試みられていて、ここにあるように「統計学は説明...

★+ ★★★

- 詰め込みすぎたので駆け足です

これまでのあらすじ: 機械学習 vs 計量経済学

AI と因果推論

機械学習の変化

AI = (計量) 経済学が証明された

これまでのあらすじ: 機械学習 **vs** 計
量経済学

前置き：統計学と計量経済学

- 統計学と計量経済学は理論的基盤が同じ.
- 以下のような観点から手法を評価する.
 - 漸近性: サンプルサイズが十分大きければ真の値 or 分布に収束するか.
 - 十分性: データから得られる情報を余さず活用しているか.
 - 効率性: 比較的/絶対的に誤差が小さいか.
- よって統計学 = 計量経済学としてあつかう.

機械学習 (教師あり学習)

- 計量経済学と機械学習で同じ手法を使っている:
 - 重回帰モデル (最小二乗法)
 - ロジスティック回帰 (GLM)
 - MCMC
 - ノンパラメトリック回帰
- 機械学習 (教師あり学習) と計量経済学はほとんど同じ?



Figure 1: 機械学習の定番テキスト

「因果」と「予測」

- Harrel (2018). (Qiitaにある翻訳)
- Hernán et al. (2019). (日本語要約: (1)(2))
- それぞれタスクが違う: 『統計学 = 因果』 『機械学習 = 予測』
 - どういう意味?



- **Varian (2014)** が紹介する例.
- 「治安の悪い地域には警官が多く配置される. だが警官の増加は治安の悪さにつながらない」




Figure 2: 肖像転載元

- 90 年代に労働経済学で因果推論が流行る.

Angrist 軍務経験は賃金プレミアムになるか (IV), 少人数教育の効果 (RDD).

Ashenfelter 双子データで教育効果比較 (IV).

Card & Krueger 州ごとの違いから最低賃金の政策効果分析 (DID).

LaLonde 思い出せない.



Figure 3: Imbens (2018) のクローズアップした先駆的な実験派たち

肖像転載元: J. D. Angrist, Orley Ashenfelter, David Card, Alan B. Krueger,
Robert LaLonde

Rubin 流因果推論と平均処置効果 (ATE)

- Rubin (1974), Rubin (1990) によるフレームワークを活用.
- 例: 生徒に対する補習は成績改善効果があるか.
- 全体平均の差が「因果関係による効果」

$$D := \begin{cases} 1 & \text{if 補習あり} \\ 0 & \text{otherwise} \end{cases}$$

$$\text{score} := Y(D)$$

$$\text{ATE} := E[Y(1)] - E[Y(0)]$$



Figure 4: Donald Rubin

- 同じ生徒の「補習を受けた場合」「受けた場合」は同時に観察できない.
- 実際に計算できるのは ATE ではなく ATT.

$$ATT := E[Y(1) \mid D = 1] - E[Y(0) \mid D = 0]$$

- ある条件のもとでは重回帰でも推定できる

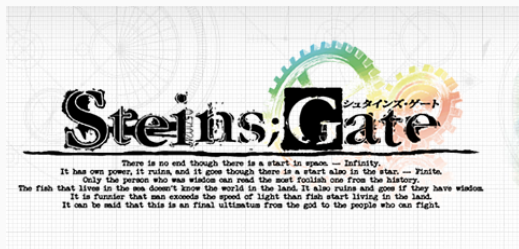
$$Y = \alpha + \tau D + \beta X + \varepsilon$$

$$E[Y] = \alpha + \tau E[D] + \beta E[X]$$

$$\tau = E[Y \mid D = 1] - E[Y \mid D = 0]$$

ランダム化比較試験 (RCT)

- 個体差があってもランダムに割り当てて平均すれば同じ.
 - RCT で得たデータ = 実験データ.
 - 対義語は観察データ.
- 相反する現実を同時に観察できたかのように推定可能.
- よって反事実的 (counterfactual).
 - 伏線回収 (1 回目)




RCT と自然実験 (準実験)

- RCT が費用・倫理面で出来ない場合も多い.
 - くじ引きで補習を決めるのは不公平
- 自然実験 (準実験) の出番.
 - IV, DID, 傾向スコアなどを使う.
- データの品質としては RCT が最良.
 - 観察データを実験データに近い品質のデータにするから「準実験」

Difference In Differences (DID)

- 一番簡単なフレームワーク
- 実質的に平均値の引き算 or 単回帰で計算できる
- DID: Y の時間差分をとり, さらに二群間の差分を取り因果効果
- DID の前提: 他に外的要因がない & 二群のトレンドが平行
 - ただし単調関数でないなら**楽しい部分識別沼**



- Angrist and Pischke (2009) 『ほとんど無害な計量経済学』
- 星野 (2009) 『調査観察データの統計科学』
- 森田 (2014) 『実証分析入門』



機械学習の出番は？

- **Athey (2018)** の主張
 - 「これまで経済学者は全部のデータで当てはめてきた」
 - 過剰適合の恐れがある.
 - 機械学習みたいにシステマティックにやろう.
 - 交差検証
 - 罰則付き回帰


- これまで内的妥当性しか言えていなかった.
 - 都内の学校のデータで因果推論は全国にも当てはまるか？
- 外的妥当性は？
 - 機械学習でもわからない
 - 機械学習で分かるのは経験損失 (empirical loss)
 - つまりデータの範囲だけ
- それって汎化してるの？ 外的妥当性は？

このセクションのまとめ

- Rubin 流因果推論は反事実的推論
- RCT が最良
- できないときは自然実験 (準実験)
- 複雑な機械学習のテクニックではなくデータの品質が重要
- 汎化/外的妥当性とは一体……うごごごご

AI と因果推論

Judea Pearl のもう 1 つの因果推論:

 Home Answer Spaces Notifications Search


Econometrics Similarities and Differences +2

What are the differences between econometrics, statistics, and machine learning?

Answer Follow · 8 Request

BI f t

4 Answers

 Judea Pearl, Professor, Author and Student
Updated Jul 7 · Upvoted by Yair Livne, Econ PhD from Stanford, 2 years of PhD stats

In comparing econometrics, statistics, and machine learning methodologies, one must distinguish between standard and advanced machine learning. The former, exemplified by deep learning and neural networks, fits a function to a stream of data and plays the same role as statistical analysis, taking us from samples to properties of distribution functions. Advanced machine learning, on

1. 「標準的機械学習と、発展的機械学習には隔たりがあると言わざるを得ない」
2. 「標準的機械学習とは、分布関数からサンプルを取り出すという、これまでの統計分析が果たしてきた役割と全く同じように、データの流に関数をあてはめているだけのディープラーニングやニューラルネットのことである。」
3. 「発展的機械学習とはデータを生成する分布を超えて、施策の介入や反事実的な理由付け (例えば、「もしこれとは異なることをしていたとしたら?」) を扱うことを可能にするものである。」

- ディープラーニングはこれまでの統計分析と同じ
 - なぜそんな爆弾発言を？

近年、驚異的な発展を見せている AI のディープラーニング (深層学習) は、原理的には単純な最小二乗法 (誤差を最小にする近似計算の一手法) にすぎない。つまり、これまで深淵な神秘とされていた知能の働きは、単純な近似計算の寄せ集めにすぎないという発見が AI の衝撃の本質である

—AI と超人類の時代弱者が持つ強み: 日本経済新聞

回答の要点: 俺の著作を読み

- **Pearl (2019)** "*The seven tools of causal inference, with reflections on machine learning*"
- 3レベル制の因果推論: 高レベルは下位レベルの問いにも答えられる

レベル/名称	モデル	問いの例
1. 関連 (association)	$p(y \mid x)$	観察された症状から病気を読み取れるか?
2. 介入 (intervention)	$p(y \mid do(x), z)$	アスピリンを飲んだら, 私の頭痛は治まるか?
3. 反事実 (counterfactual)	$p(y_x \mid x', y')$	アスピリンは私の頭痛を止めたか? 私が過去2年間禁煙していたらどうなっていたか?

- レベル 1 = 標準的機械学習
 - 単に相関を見ているだけ
- レベル 2 = Rubin 流因果推論
 - Pearl 的には反事実ではなく介入.
- レベル 3 は Why? に答える.
 - 現実と全く違う状況ならどうなるかという問い
 - Pearl の提案する構造的因果モデル

- グラフ (DAG) で書かれた理論
 - 確率分布で書いてくれないとわかりにくい
- 数日前に **Imbens (2019)** の Rubin と Pearl の理論を比較する 70 ページの論文が arXiv に投稿される
 - 変数が多いときは便利だが仮定が強すぎると指摘

- 介入効果にあたる Rubin 流因果推論はどうなったのか
- 最近は特にこの 3 人の名前が目立つ?
 - 左 2 人は Stanford 大ビジネススクールに所属




Figure 6: 近年注目される計量経済学者

肖像転載元: Susan Athey, Guido Imbens, Viktor V.
Chernozhukov

1. Wager and Athey (2018) Causal Tree (Causal Forest) (日本語解説)
 2. Athey et al. (2019) Generalized Random Forest (日本語解説)
- どちらも機械学習のランダムフォレストを利用して, 異質処置効果 (HTE) を推定するアルゴリズム
 - 「平均」処置効果ではなく個体ごとに異なる効果
 - 数理統計学的な漸近理論で性能を保証
 - R のパッケージあり

1. Belloni et al. (2014), Chernozhukov et al. (2017), Chernozhukov et al. (2018), Belloni et al. (2017) で二重バイアス除去機械学習 (DML; Double/Debiased Machine Learning (DML)) を考案
 - TokyoR #71 での発表 で R のサンプルコードあり
 - 部分線形 (セミパラメトリック) モデルには内生性がある
 - 高次元の場合にも対応
 - Chernozhukov and Hansen (2005), Chernozhukov et al. (2007) では部分識別の研究もしている.

- Brodersen et al. (2015) による, ベイズ構造時系列モデルと Synthetic Control の組み合わせ
 - SC では対照群を擬似的に生成
 - BSTS x SC で時系列モデルの構造を考えずに施策の因果効果を継続してモニタリング可
- DID の前提: 他に外的要因がない & 二群のトレンドが平行
 - SC は 2 番めの制約なし
- TJO ブログ や Tokyo.R #75 の応用セッション でも紹介

豆知識: 最初に機械学習を研究した計量経済学者は誰?

- 自分の知る限り **Hornik et al. (1989)** のうち, Halbert White.
 - **Cybenko (1989)** と同時期に DNN の万能近似定理を研究



Figure 7: Halbert White (肖像転載元)

機械学習の変化

- Pearl (2019) は因果推論の 7 つ道具を提示
- 機械学習研究再度でも因果推論に向かっているものがある

- 標準的機械学習が関連分析しかできないのは環境の変化を考慮していないから
 - 転移学習 (ドメイン適応)
 - life-long learning
 - Explainable AI (XAI)
- 因果推論という傾向スコアと同じ発想

- Amazon の採用選好 AI が応募者を女性というだけでマイナス評価
- Dwork et al. (2012), 神嶌 (2017), Barocas et al. (2018) など言及.
- 経済学で言う統計的差別と同じ現象
 1. 雇用主始めから偏見があり女性冷遇
 2. 冷遇するので優秀な女性人材が集まらない
 - 偶然優秀な女性が来ないことでも起こりうる
 3. 雇用主「やっぱり女性は使えない」と見える
 4. 「統計的には」差別することが合理的であるように見えてしまう
- 「公平性を評価するスコア」は経済学にはない新しいアイディア

- 清水 (2017), ?
- Pearl の DAG を仮定して機械的に因果効果を発見しよう
- 線形非ガウシアン非巡回モデル (LiNGAM)

AI = (計量) 経済学が証明された

- 数日前に **Igami (2018)** のやばい論文 (?) を読んでしまったので紹介
- Deep Blue (**Campbell et al., 2002**)
- Bonanza (**保木・渡辺, 2007**)
- AlphaGo (**Silver et al., 2016**)
- これらは全て経済学の構造推定モデルと同じことをしている!

- ゲームの状態は全て 1 手前に依存するので, 以下のように書ける.

$$s_{t+1} = f(a_t, s_t)$$

- t は現在何手目か
- s_t は駒の配置を表す状態変数
- a_t は打つ手
- s_t, a_t で勝つ確率が決まる. 勝率を $V(s_t; \theta)$ と仮定し, 毎ターン勝率を最大化するように手 a_t^* を決める

$$a_t^* := \arg \max_{a_t \in \mathcal{A}} V(s_t; \theta)$$

- s_t は s_{t-1}, a_{t-1} に依存. a_1^*, a_1^*, a_3^* , と再帰的に選ぶ必要.
- 価値関数 $V(s_t; \theta)$ と政策関数 $a_t^* = \sigma(s_t; \theta)$ を知りたい.

- ゲーム展開は木構造で列挙できる
- 1. θ は 8,150 個あったが手動で調整
- 2. 対戦中は探索木アルゴリズムで最適な手を探す
- 安定してプロに勝てるようになるまで繰り返し

- θ は約 50,000,000 個, 約 5,000,000 手のデータで学習

1. データより θ が多いので機械学習 (スパース推定) で求めた

2. Value Function Iteration

- 機械学習で求めた θ から $a_t^* = \sigma(s_t; \theta)$ を計算
 - $V(s_t; \theta)$ が収束するまで繰り返す.
 - 収束した $V(s_t; \theta)$ をもとに θ を再度推定.
 - 両方が収束するまで以上を繰り返す.
-
- これは計量経済学の Rust (1987) による動学的構造推定と同じ!!
 - 山口 (2017) による構造推定の解説

Alpha Go (初期バージョン)

- パラメータは 4,600,000 個, 256,000,000 手のデータで学習
1. 畳み込みニューラルネット (CNN) で推定 (SL policy network)
 2. パラメータや状態をランダムにずらして対戦させて戦績の良いものを選ぶ (RL policy network)
 3. (2) の RL network の対戦成績もデータに加えて CNN で $V(s_t; \theta)$ を推定.
 4. モンテカルロ木探索で最適手を探索
- Hotz and Miller (1993), Hotz et al. (1994) と同じだと指摘

- 初期バージョンの人間の対戦データを学習させる過程を省いて、オリジナルを上回る戦果
- 構造推定の1段階目でも自由度の高いノンパラメトリックなモデルでの当てはめが好まれる.
- ディープラーニングや強化学習が経済学で使われる日も近い?

- 構造推定モデルも反事実モデルの一種
- RCT や自然実験をしなくても反事実的な因果効果を見られる
- 数値計算の知識もいるのであまり流行ってない

- 機械学習 VS 計量経済学という認識も時代遅れに
 - 共変量 (特徴量) 分布の変化に強いモデルを作る必要あり
 - どちらも自身の欠点を意識しより適切な因果推論へ
- 強化学習や機械学習側のリサーチは時間不足で中途半端に
- いかがでしたか登壇は回避
 - そしてキュレーション登壇へ
- R の応用セッションとは一体....

- Angrist, Joshua D and Jörn-Steffen Pischke (2009) *Mostly Harmless Econometrics: An Empiricist's Companion*: Princeton University Press, (大森義明・小原美紀・田中隆一・野口晴子訳, 『ほとんど無害な計量経済学－応用経済学のための実証分析ガイド－』, NTT 出版, 2013 年) .
- Athey, Susan (2017) “Beyond Prediction: Using Big Data for Policy Problems,” *Science*, Vol. 355, No. 6324, pp. 483-485, February, DOI: [10.1126/science.aal4321](https://doi.org/10.1126/science.aal4321).
- (2018) “The Impact of Machine Learning on Economics,” in *The Economics of Artificial Intelligence: An Agenda*: University of Chicago Press, pp. 507-547, DOI: <https://doi.org/10.7208/chicago/9780226613475.001.0001>.

- Athey, Susan, Julie Tibshirani, and Stefan Wager (2019)
“Generalized Random Forests,” *The Annals of Statistics*, Vol. 47, No. 2, pp. 1148-1178, April, DOI: [10.1214/18-AOS1709](https://doi.org/10.1214/18-AOS1709).
- Barocas, Solon, Moritz Hardt, and Arvind Narayanan (2018)
Fairness and Machine Learning: fairmlbook.org.
- Belloni, Alexandre, Victor Chernozhukov, and Christian Hansen (2014) “High-Dimensional Methods and Inference on Structural and Treatment Effects,” *Journal of Economic Perspectives*, Vol. 28, No. 2, pp. 29-50, May, DOI: [10.1257/jep.28.2.29](https://doi.org/10.1257/jep.28.2.29).

Belloni, Alexandre, Viktor Chernozhukov, I. Fernández-Val, and Christian Hansen (2017) “Program Evaluation and Causal Inference With High-Dimensional Data,” *Econometrica*, Vol. 85, No. 1, pp. 233-298, DOI: [10.3982/ECTA12723](https://doi.org/10.3982/ECTA12723).

Brodersen, Kay H., Fabian Gallusser, Jim Koehler, Nicolas Remy, and Steven L. Scott (2015) “Inferring Causal Impact Using Bayesian Structural Time-Series Models,” *The Annals of Applied Statistics*, Vol. 9, No. 1, pp. 247-274, March, DOI: [10.1214/14-AOAS788](https://doi.org/10.1214/14-AOAS788).

Campbell, Murray, A. Joseph Hoane, and Feng-hsiung Hsu (2002) “Deep Blue,” *Artificial Intelligence*, Vol. 134, No. 1-2, pp. 57-83, January, DOI: [10.1016/S0004-3702\(01\)00129-1](https://doi.org/10.1016/S0004-3702(01)00129-1).

Chernozhukov, Victor and Christian Hansen (2005) “An IV Model of Quantile Treatment Effects,” *Econometrica*, Vol. 73, No. 1, pp. 245-261, January, DOI: [10.1111/j.1468-0262.2005.00570.x](https://doi.org/10.1111/j.1468-0262.2005.00570.x).

Chernozhukov, Victor, Han Hong, and Elie Tamer (2007) “Estimation and Confidence Regions for Parameter Sets in Econometric Models,” *Econometrica*, Vol. 75, No. 5, pp. 1243-1284, September, DOI: [10.1111/j.1468-0262.2007.00794.x](https://doi.org/10.1111/j.1468-0262.2007.00794.x).

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, and Whitney Newey (2017) “Double/Debiased/Neyman Machine Learning of Treatment Effects,” *American Economic Review*, Vol. 107, No. 5, pp. 261-265, May, DOI: [10.1257/aer.p20171038](https://doi.org/10.1257/aer.p20171038).

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, Whitney Newey, and James Robins (2018) “Double/Debiased Machine Learning for Treatment and Structural Parameters,” *The Econometrics Journal*, Vol. 21, No. 1, pp. C1-C68, February, DOI: [10.1111/ectj.12097](https://doi.org/10.1111/ectj.12097).

Cybenko, George (1989) “Approximation by Superpositions of a Sigmoidal Function,” *Mathematics of Control, Signals, and Systems*, Vol. 2, No. 4, pp. 303-314, December, DOI:

[10.1007/BF02551274](https://doi.org/10.1007/BF02551274).

Dwork, Cynthia, Moritz Hardt, Toniann Pitassi, Omer Reingold, and Richard Zemel (2012) “Fairness through Awareness,” in *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference on - ITCS '12*, pp. 214-226, Cambridge, Massachusetts: ACM Press, DOI:

[10.1145/2090236.2090255](https://doi.org/10.1145/2090236.2090255).

Harrel, Frank (2018) “Road Map for Choosing Between Statistical Modeling and Machine Learning,” September, 和訳: 西田勘一郎『統計のモデルと機械学習のモデル、どう使い分ければよいのか』.

Hernán, Miguel A., John Hsu, and Brian Healy (2019) “A Second Chance to Get Causal Inference Right: A Classification of Data Science Tasks,” *CHANCE*, Vol. 32, No. 1, pp. 42-49, January, DOI: [10.1080/09332480.2019.1579578](https://doi.org/10.1080/09332480.2019.1579578), 西田勘一郎による要約: 『予測と因果関係は何が違うのか - Part 1』『予測と因果関係 - Part 2: 予測は自動化できても因果推論は自動化できない』.

- Hornik, Kurt, Maxwell Stinchcombe, and Halbert White (1989) “Multilayer Feedforward Networks Are Universal Approximators,” *Neural Networks*, Vol. 2, No. 5, pp. 359-366, January, DOI: [10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8).
- Hotz, V. J., R. A. Miller, S. Sanders, and J. Smith (1994) “A Simulation Estimator for Dynamic Models of Discrete Choice,” *The Review of Economic Studies*, Vol. 61, No. 2, pp. 265-289, April, DOI: [10.2307/2297981](https://doi.org/10.2307/2297981).
- Hotz, V Joseph and Robert A. Miller (1993) “Conditional Choice Probabilities and the Estimation of Dynamic Models,” *Review of Economic Studies*, Vol. 60, No. 3, pp. 497-529, DOI: [10.2307/2298122](https://doi.org/10.2307/2298122).

Igami, Mitsuru (2018) “Artificial Intelligence as Structural Estimation: Economic Interpretations of Deep Blue, Bonanza, and AlphaGo,” Technical report.

Imbens, Guido (2018) “Causal Inference and Machine Learning,” <https://times.tinbergen.nl/causal-inference-and-machine-learning/>, June.

Imbens, Guido W. (2019) “Potential Outcome and Directed Acyclic Graph Approaches to Causality: Relevance for Empirical Practice in Economics,” Technical report.

- Mullainathan, Sendhil and Jann Spiess (2017) “Machine Learning: An Applied Econometric Approach,” *Journal of Economic Perspectives*, Vol. 31, No. 2, pp. 87-106, May, DOI: [10.1257/jep.31.2.87](https://doi.org/10.1257/jep.31.2.87).
- Pearl, Judea (2019) “The Seven Tools of Causal Inference, with Reflections on Machine Learning,” *Communications of the ACM*, Vol. 62, No. 3, pp. 54-60, February, DOI: [10.1145/3241036](https://doi.org/10.1145/3241036).
- Rubin, Donald B. (1974) “Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies.,” *Journal of Educational Psychology*, Vol. 66, No. 5, pp. 688-701, DOI: [10.1037/h0037350](https://doi.org/10.1037/h0037350).

- (1990) “Comment: Neyman (1923) and Causal Inference in Experiments and Observational Studies,” *Statistical Science*, Vol. 5, No. 4, pp. 472-480, November, DOI: [10.1214/ss/1177012032](#), On the Application of Probability Theory to Agricultural Experiments. Essay on Principles. Section 9.
- Rust, John (1987) “Optimal Replacement of GMC Bus Engines: An Empirical Model of Harold Zurcher,” *Econometrica*, Vol. 55, No. 5, p. 999, September, DOI: [10.2307/1911259](#).

- Silver, David, Aja Huang, Chris J. Maddison, Arthur Guez, Laurent Sifre, George van den Driessche, Julian Schrittwieser, Ioannis Antonoglou, Veda Panneershelvam, Marc Lanctot, Sander Dieleman, Dominik Grewe, John Nham, Nal Kalchbrenner, Ilya Sutskever, Timothy Lillicrap, Madeleine Leach, Koray Kavukcuoglu, Thore Graepel, and Demis Hassabis (2016) "Mastering the Game of Go with Deep Neural Networks and Tree Search," *Nature*, Vol. 529, No. 7587, pp. 484-489, January, DOI: [10.1038/nature16961](https://doi.org/10.1038/nature16961).
- Varian, Hal R. (2014) "Big Data: New Tricks for Econometrics," *Journal of Economic Perspectives*, Vol. 28, No. 2, pp. 3-28, May, DOI: [10.1257/jep.28.2.3](https://doi.org/10.1257/jep.28.2.3).

Wager, Stefan and Susan Athey (2018) “Estimation and Inference of Heterogeneous Treatment Effects Using Random Forests,” *Journal of the American Statistical Association*, Vol. 113, No. 523, pp. 1228-1242, July, DOI: [10.1080/01621459.2017.1319839](https://doi.org/10.1080/01621459.2017.1319839).

清水昌平 (2017) 『統計的因果探索』，機械学習プロフェッショナルシリーズ，講談社，東京都文京区．

星野崇宏 (2009) 『調査観察データの統計科学－因果推論・選択バイアス・データ融合』，岩波書店．

森田果 (2014) 『実証分析入門: データから「因果関係」を読み解く作法』，日本評論社，東京，OCLC: 881836881．

山口慎太郎 (2017) 「動学的離散選択モデルの構造推定」, 『第 20 回労働経済学カンファレンス』, 東京, 9 月.

保木邦仁・渡辺明 (2007) 『ボナンザ vs 勝負脳: 最強将棋ソフトは人間を超えるか』, KADOKAWA, 東京; 東京, OCLC: 676002553.

神瀧敏弘 (2017) 「公平配慮型データマイニング技術の進展」, 『第 31 回人工知能学会全国大会論文集』, 一般社団法人人工知能学会, DOI: [10.11517/pjsai.JSAI2017.01E1OS24a1](https://doi.org/10.11517/pjsai.JSAI2017.01E1OS24a1).